

# SVM



回顾LR

支持向量机其基本原理，通俗来讲，它是一种二类分类模型，其基本模型定义为特征空间上的间隔最大的线性分类器，其学习策略便是间隔最大化。线性分类器使用超平面类型的边界，非线性分类器使用超曲面。

**数据：**线性可分&线性不可分

## 两种情况

- 线性可分
- 线性不可分

情况1：样本本质上是非线性可分的

解决方法：核函数


情况2：本质上线性，非线性由噪音导致  
强制使用非线性函数，会导致过拟合


解决方法：软间隔

## 线性可分



定义：

对于来自两类的一组模式能用一个线性判别函数正确分类，  
则称他们是线性可分的。





线性不可分






慧科集团旗下企业

# 线性可分情况

• 我们怎样才能取得一个最优的划分直线 $f(x)$ 呢？


$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b$$



$\mathbf{W}$  权重向量，需要学习的参数  
 $b$  为偏差，需要学习的参数





$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$



多维超平面


## 最大间隔





$y \in \{-1, +1\}$

$$\hat{\gamma} = y(w^T x + b) = yf(x)$$



## 几何间隔

- 点到直线:

$$\tilde{\gamma} = \frac{\hat{\gamma}}{\|w\|} = \frac{w^T x}{\|w\|} + \frac{b}{\|w\|} = \frac{f(x)}{\|w\|}$$

- 这时如果成比例的改变 $w$ 和 $b$ , 几何间隔的值不会发生改变。

因此，我们的最大间隔分类的目标函数可以定义为：

$$\max \frac{\hat{\gamma}}{\|w\|}$$

$$s.t. \dots y^{(i)} (w^T x^{(i)} + b) \geq \hat{\gamma}$$

我们改变优化问题的表述方式。

此时，优化问题的表达式为：

$$\begin{aligned} \min & \frac{1}{2} \|w\|^2 \\ s.t. & y^{(i)} (w^T x^{(i)} + b) \geq 1 \end{aligned}$$

我们的优化问题转变成了一个凸优化问题

## 拉格朗日乘子法

- $\min f(w)$
- s.t.  $g_i(w) \leq 0 \quad i=1,2,\dots,k$

$h_i(w)=0 \quad i=1,2,\dots,l$  （这里0指的是零向量）

$$L(w, \alpha, \beta) = f(w) + \sum_{i=1}^k \alpha_i g_i(w) + \sum_{i=1}^l \beta_i h_i(w)$$

定义:  $\theta_p(w) = \max_{\alpha_i \geq 0} L(w, \alpha, \beta)$

当所有约束条件都满足时有  $\theta_p = f(w)$

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1)$$



## 对偶问题

$$p^* = \min_{w,b} \theta(w) = \min_{w,b} \max_{\alpha_i \geq 0} L(w,b,a)$$

$$d^* = \max_{\alpha_i \geq 0} \min_{w,b} L(w,b,a)$$

一般有  $d^* \leq p^*$ ，但是在某些特定条件下（KKT），这两个最优化问题会取相同的值。

1. 首先固定 $\alpha$ ，要让 $L$ 关于 $w$ 和 $b$ 最小化，我们分别对 $w, b$ 偏导并令其等于零，得到

$$\frac{\partial L}{\partial w} = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\frac{\partial L}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

带回  $L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i (y_i (w^T x_i + b) - 1)$  得到：

$$\begin{aligned} \mathcal{L}(w, b, \alpha) &= \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - b \sum_{i=1}^n \alpha_i y_i + \sum_{i=1}^n \alpha_i \\ &= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \end{aligned}$$

问题转换为:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\ \text{s.t.}, \quad & \alpha_i \geq 0, i = 1, \dots, n \\ & \sum_{i=1}^n \alpha_i y_i = 0 \end{aligned}$$

由凸二次规划的性质能保证这样最优的向量 $\mathbf{a}$ 是存在的

- 2.求对 $\alpha$ 的极大，即是关于对偶变量的优化问题  
(SMO优化算法--序列最小最优化算法)

- 然后根据

$$w^* = \sum_{i=1}^n \alpha_i y_i x_i$$

$$b^* = -\frac{\max_{i:y_i=-1} w^{*T} x_i + \min_{i:y_i=1} w^{*T} x_i}{2}$$

- 可求出最优的 $w$ 和 $b$ ，即最优超平面。



慧科集

**例 7.1** 数据与例 2.1 相同。已知一个如图 7.4 所示的训练数据集，其正例点是  $x_1 = (3, 3)^T$ ， $x_2 = (4, 3)^T$ ，负例点是  $x_3 = (1, 1)^T$ ，试求最大间隔分离超平面。




图 7.4 间隔最大分离超平面示例

**解** 按照算法 7.1，根据训练数据集构造约束最优化问题：

$$\begin{aligned} \min_{w, b} \quad & \frac{1}{2}(w_1^2 + w_2^2) \\ \text{s.t.} \quad & 3w_1 + 3w_2 + b \geq 1 \\ & 4w_1 + 3w_2 + b \geq 1 \\ & -w_1 - w_2 - b \geq 1 \end{aligned}$$

$$-\frac{1}{2}(18\alpha_1^2 + 25\alpha_2^2 + 2\alpha_3^2 + 42\alpha_1\alpha_2 - 12\alpha_1\alpha_3 - 14\alpha_2\alpha_3) + \alpha_1 + \alpha_2 + \alpha_3$$

$$\alpha_1 + \alpha_2 - \alpha_3 = 0$$

$$\alpha_i \geq 0, \quad i = 1, 2, 3$$

$$\alpha_i - \frac{1}{2} \sum_{j=1}^n \alpha_j y_j y_i x_i^T x_j$$

$$\geq 0, i = 1, \dots, n$$

$$\alpha_i y_i = 0$$

将  $\alpha_1 + \alpha_2 = \alpha_3$   
代入目标函数，得到关于  $\alpha_1, \alpha_2$  的函数：

$$-4\alpha_1^2 - \frac{13}{2}\alpha_2^2 - 10\alpha_1\alpha_2 + 2\alpha_1 + 2\alpha_2$$

$$\alpha_i \geq 0, \quad i = 1, 2, 3$$

$$\alpha_1 = 1/4$$

$$\alpha_2 = 0$$

$$\alpha_3 = 1/4$$

代入公式：

$$w^* = \sum_{i=1}^n \alpha_i y_i x_i$$
$$b^* = -\frac{\max_{i:y_i=-1} w^{*T} x_i + \min_{i:y_i=1} w^{*T} x_i}{2}$$

求得此最优化问题的解  $w_1 = w_2 = \frac{1}{2}$ ， $b = -2$ 。于是最大间隔分离超平面为

$$\frac{1}{2}x^{(1)} + \frac{1}{2}x^{(2)} - 2 = 0$$

其中， $x_1 = (3, 3)^T$  与  $x_3 = (1, 1)^T$  为支持向量。



首先给出形式化的不等式约束优化问题：

$$\begin{aligned} \min_x \quad & f(x) \\ \text{s.t.} \quad & h_i(x) = 0, \quad i = 1, 2, \dots, m \\ & g_j(x) \leq 0, \quad j = 1, 2, \dots, n \end{aligned}$$

列出 Lagrangian 得到无约束优化问题：

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^m \alpha_i h_i(x) + \sum_{j=1}^n \beta_j g_j(x)$$

经过之前的分析，便得知加上不等式约束后可行解  $x$  需要满足的就是以下的 KKT 条件：

$$\nabla_x L(x, \alpha, \beta) = 0 \tag{1}$$

$$\beta_j g_j(x) = 0, \quad j = 1, 2, \dots, n \tag{2}$$

$$h_i(x) = 0, \quad i = 1, 2, \dots, m \tag{3}$$


$$g_j(x) \leq 0, \quad j = 1, 2, \dots, n \tag{4}$$

$$\beta_j \geq 0, \quad j = 1, 2, \dots, n \tag{5}$$



哪个划分更好？

## 软间隔



允许一定程度犯错




$$\min_{\mathbf{w} \in \mathbb{R}^d, \xi_i \in \mathbb{R}^+} \|\mathbf{w}\|^2 + C \sum_i^N \xi_i$$

$$\xi_i \geq 0$$

$$y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i \text{ for } i = 1 \dots N$$

$$y_i f(\mathbf{x}_i) \geq 1 - \xi_i$$

$$\xi_i = \max(0, 1 - y_i f(\mathbf{x}_i))$$




$$\min_{\mathbf{w} \in \mathbb{R}^d} \underbrace{\|\mathbf{w}\|^2}_{\text{regularization}} + C \sum_i^N \underbrace{\max(0, 1 - y_i f(\mathbf{x}_i))}_{\text{loss function}}$$



慧科集团旗

$C = \text{Infinity}$  hard margin



C的取值和带宽

$C = 10$  soft margin

